

**PONTIFÍCIA UNIVERSIDADE CATÓLICA DO PARANÁ  
ESCOLA POLITÉCNICA  
CURSO DE ENGENHARIA DE COMPUTAÇÃO**

**PEDRO HENRIQUE CAVALHIERI CONTESSOTO  
JEFFERSON SOBRINHO ABBIN**

**PROJETO COMPILADOR (FASE 1)**

**CURITIBA  
2023**

**PEDRO HENRIQUE CAVALHIERI CONTESSOTO**  
**JEFFERSON SOBRINHO ABBIN**

**PROJETO COMPILADOR (FASE 1)**

Atividade avaliativa de Curso de  
Linguagens Formais e Compiladores da  
Pontifícia Universidade Católica do  
Paraná

Orientador: Me. Eng. Frank Coelho de  
Alcantara

**CURITIBA**  
**2023**

## 1 FASE 1 – DEFINIÇÃO DA LINGUAGEM E ANÁLISE LÉXICA

Para definição da linguagem de programação foi definida a seguinte bloco de declarações pela lista abaixo, com declarações terminais estão em **negrito**:

```

program → block
block → {decls stmts}
decls → decls decl | e
decl → type id
type → type [num] | basic
stmts → stmts stmt | e
bool → bool || join | join
join → join && equality | equality
equality → equality == rel | equality != rel | rel
rel → expr < expr | expr <= expr | expr >= expr | expr > expr | expr
expr → expr + term | expr - term | term
term → term * unary | term / unary | unary
unary → !unary | unary | factor
factor → (bool) | num | real | true | false | string
stmt → if (bool) stmt
stmt → if (bool) stmt else stmt
stmt → while ( bool ) stmt
stmt → do stmt while (bool)
stmt → break
stmt → WritePort (string, true | false )
stmt → ReadPort (string, string)
stmt → ReadSerial (string, expr)
stmt → WriteSerial (string, string )
stmt → Writeanalog (string, expr )
stmt → Readanalog (string, string)
stmt → sleep (expr)
num → {0 - 65.536}
char → {0 - 9} || {A - z} || {A - Z} || {!@#$%`&*()_+=}
```

Para a seguinte linguagem segue 3 (Três) exemplos código com suas funcionalidades de possíveis:

#### EXEMPLOS

```
1) IF (X > 12){
    WRITE SERIAL(S3, 2301)
}
```

```
2) while (x < 12){
    buffer = !buffer
    WRITE PORT(D1, BUFFER)
    SLEEP (10)
    x = x +1
}
```

```
3) x = READ ANALOG (A2, BUFFER)
    IF (BUFFER > 3000){
        WRITE SERIAL(S3, "PRESSÃO ELEVADA")
    }
```

Para a etapa da análise Léxica foi desenvolvido o código para realizar a mesmo, conforme solicitado o código é capaz de validar todos os possíveis lexemas da linguagem, usando máquinas de estado finito, implementado em Python.

Temos a primeira etapa do código onde inicializado os estados inicial

```
def __init__(self):
    self.state = 'START'
    self.lexeme = ""
    self.tokens = []
    self.position = 0
```

Abaixo esta definição dos estados de transição:

```
def transition(self, char):
    if self.state == 'START':
        if char in [' ', '\n', '\t']: # Skip whitespace
            self.position += 1
            return
        elif char.isalpha() or char == '_':
            self.state = 'IDENTIFIER'
        elif char.isdigit():
            self.state = 'NUMBER'
        elif char in ['=', '!', '<', '>', '+', '-', '*', '/']:
            self.state = 'OPERATOR'
        elif char in ['(', ')', '{', '}', '[', ']', ',', ';']:
            self.state = 'MARKERS'
        else:
            print(f"Invalid token: {char}")
            return

    self.lexeme += char
    elif self.state == 'IDENTIFIER':
        if char.isalpha() or char.isdigit() or char == '_':
            self.lexeme += char
            elif self.lexeme in ["if", "while", "break", "do", "sleep", "WritePort", "ReadPort",
"ReadSerial", "WriteSerial", "Writeanalog", "Readanalog"]:
                self.emit('KEYWORD')
                self.transition(char)
            else:
                self.emit('IDENTIFIER')
                self.transition(char) # reprocess the current character
    elif self.state == 'NUMBER':
        if char.isdigit():
            self.lexeme += char
        elif char == '.':
            self.state = 'REAL'
```

```

        self.lexeme += char
    else:
        self.emit('NUMBER')
        self.transition(char) # reprocess the current character
elif self.state == 'REAL':
    if char.isdigit():
        self.lexeme += char
    else:
        self.emit('REAL')
        self.transition(char) # reprocess the current character
elif self.state == 'OPERATOR':
    self.lexeme += char
    if not self.lexeme in ['==', '!=', '<=', '>=']:
        self.lexeme = self.lexeme[:-1]
        self.emit('OPERATOR')
        self.transition(char) # reprocess the current character

elif self.state == 'MARKERS':
    self.lexeme += char
    self.lexeme = self.lexeme[:-1]
    self.emit('MARKERS')
    self.transition(char) # reprocess the current character

```

Abaixo as funções de auxiliares para definição dos tokens reconhecidos:

```

emit(self, token_type):
    self.tokens.append((token_type, self.lexeme, self.position))
    self.position += len(self.lexeme)
    self.lexeme = ""
    self.state = 'START'

def tokenize(self, code):
    for char in code:
        self.transition(char)
    if self.lexeme: # handle the last token

```

```

        self.emit(self.state)
    return self.tokensxiliares

def emit(self, token_type):
    self.tokens.append((token_type, self.lexeme, self.position))
    self.position += len(self.lexeme)
    self.lexeme = ""
    self.state = 'START'

def tokenize(self, code):
    for char in code:
        self.transition(char)
    if self.lexeme: # handle the last token
        self.emit(self.state)
    return self.tokens

```

Abaixo as funções para ler o arquivo e cria as tabela de tokens:

```

def read_code_from_file(file_name):
    with open(file_name, 'r') as file:
        code = file.read()
    return code

def create_token_table(tokens, file_name):
    with open(file_name, 'w') as file:
        for token_type, token, position in tokens:
            file.write(f"Token: {token}, Classe: {token_type}, Posição: {position}\n")

```

E por último a função principal para rodar o código:

```

if __name__ == "__main__":
    if sys.argv[1] != "code1.txt" and sys.argv[1] != "code2.txt" and sys.argv[1] !=
"code3.txt":
        print("Arquivo nao existe, escolha: code1.txt, code2.txt ou code3.txt")
        exit(1)

```

```
code = read_code_from_file(sys.argv[1])
analyzer = LexicalAnalyzerFSM()
tokens = analyzer.tokenize(code)
create_token_table(tokens, "token_table.txt")
```

Como Solicitado analisador léxico deve recebe o arquivo de textos contendo codigo, na linha de comando conforme Figura 01

```
~/Analizador-Lexico$ python main.py code1.txt
~/Analizador-Lexico$
```

Figura 1 - Print da linha de comando.

Fonte: autores, 2023.

e retornando o token identificado a sua classe e sua posição no arquivo exemplificado na figura 02

```
token_table.txt
1 Token: if, Classe: KEYWORD, Posição: 0
2 Token: (, Classe: MARKERS, Posição: 3
3 Token: X, Classe: IDENTIFIER, Posição: 4
4 Token: >, Classe: OPERATOR, Posição: 6
5 Token: 12, Classe: NUMBER, Posição: 8
6 Token: ), Classe: MARKERS, Posição: 10
7 Token: {, Classe: MARKERS, Posição: 11
8 Token: WriteSerial, Classe: KEYWORD, Posição: 14
9 Token: (, Classe: MARKERS, Posição: 25
10 Token: s3, Classe: IDENTIFIER, Posição: 26
11 Token: ,, Classe: MARKERS, Posição: 28
12 Token: 2301, Classe: NUMBER, Posição: 30
13 Token: ), Classe: MARKERS, Posição: 34
14 Token: }, Classe: MARKERS, Posição: 37
15
```

Figura 1 - Arquivo de saída Analisador Léxico.

Fonte: autores, 2023.

Link para repositório do GitHub: [https://github.com/JeffAbbin/Projeto\\_Compilador-](https://github.com/JeffAbbin/Projeto_Compilador-)

Link para rodar o código no replt:

<https://replit.com/@JeffersonAbbin/Analizador-Lexico#main.py>



Link2 para rodar o código no replt: <https://replit.com/join/mjgkqebsex-jeffersonabbin>

## REFERÊNCIAS

LINGUAGEM de programação e Compiladores. [S. l.], 1 jan. 2021. Disponível em: <https://frankalcantara.com/Ling-programacao-compiladores/>. Acesso em: 16 abr. 2023.

REGEX refence. [S. l.], 16 abr. 2023. Disponível em: <https://regexr.com/>. Acesso em: 16 abr. 2023.

WHAT is ANTLR?. [S. l.], 25 maio 2023. Disponível em: <https://www.antlr.org>. Acesso em: 25 maio 2023.

ANALISE Léxica. [S. l.], 25 maio 2023. Disponível em: <https://johnidm.gitbooks.io/compiladores-para-humanos/content/part1/lexical-analysis.html>. Acesso em: 25 maio 2023.